

Resumo: Integrating LLMs with Cloud-Native Observability for Automated Root Cause Analysis and Remediation

Referência: WANG, C. et al. *Integrating Large Language Models with Cloud-Native Observability for Automated Root Cause Analysis and Remediation*. Proceedings of the 3rd International Conference on Artificial Intelligence, Systems and Network Security, 2025.

Contexto e Problema

Sistemas *cloud-native* modernos (baseados em microsserviços e contêineres) geram um volume massivo de telemetria (*metrics*, *logs* e *traces*), tornando o monitoramento tradicional baseado em regras ineficaz. Equipes de SRE sofrem com grande carga cognitiva para correlacionar esses dados e investigar incidentes em tempo hábil. Embora os LLMs ofereçam um alto potencial para automatizar a Análise de Causa Raiz (RCA), sua aplicação direta esbarra em limites de janela de contexto, na falta de conhecimento do domínio operacional e na necessidade de realizar um raciocínio causal preciso e seguro.

Metodologia (Solução Proposta)

O artigo propõe um *framework* de quatro camadas: coleta via OpenTelemetry, detecção de anomalias por algoritmos tradicionais, RCA aprimorada por LLM e remediação automatizada. Para superar os limites de contexto da IA, o sistema extrai e sumariza os dados apenas nas janelas de tempo cruciais. O LLM (treinado a partir do Llama-2-13B) passa por um rigoroso processo de *fine-tuning* e Otimização Direta de Preferência (DPO). A arquitetura aplica a fusão multimodal (*Cross-Modal Attention*) para unificar as métricas aos *logs* do sistema. Por fim, o agente utiliza engenharia de *prompt* via *Chain-of-Thought* (CoT) (raciocínio passo a passo) para construir a hipótese de causa raiz e validar a segurança de um roteiro autônomo de remediação.

Resultados Obtidos (e Avaliação)

Nos testes utilizando *benchmarks* públicos de microsserviços sob cenários de falhas induzidas, a abordagem alcançou um impressionante *F1-Score* de 95% na detecção correta. Destaca-se a redução de 84,2% no Tempo Médio de Resolução (MTTR) frente aos métodos baseados em regras, atingindo uma taxa de automação de 91% na resolução de incidentes sem intervenção humana. O estudo de ablação demonstrou que tanto a fusão multimodal quanto a especialização do domínio via *fine-tuning* são essenciais para essa precisão.

Relação com este TCC

Este artigo tem altíssima relevância conceitual e técnica para o TCC, pois comprova no estado da arte a eficácia exata do *pipeline* que está sendo idealizado no trabalho: utilizar o ecossistema e algoritmos padrões de monitoramento para atuar como gatilhos, e acionar a inteligência do LLM estritamente como um motor de inferência da RCA (injetando-lhe o contexto mastigado e condensado). Além disso, o trabalho corrobora a premissa de que submeter dados cegamente aos modelos não funciona; o controle do limite do contexto, aliando as métricas com *logs* relevantes (multimodal), constitui a chave metodológica que este TCC deverá focar para viabilizar os diagnósticos rápidos.