

Resumo: A Survey of AIOps in the Era of Large Language Models

Referência: LIU, J. et al. *A Survey of AIOps in the Era of Large Language Models*. ACM Computing Surveys, 2024.

Contexto e Problema

O estudo revisou 183 artigos sobre a aplicação de Modelos de Linguagem de Grande Escala (LLMs) em AIOps entre 2020 e 2024. Constatou-se que o cenário de dados mudou significativamente: o monitoramento tradicional dependia unicamente de dados gerados por máquinas (métricas, *logs* e *traces*), o que exigia intensa engenharia manual de *features* para o uso de modelos de *machine learning*. A integração dos LLMs resolve esse problema devido à sua capacidade de ler texto nativamente, permitindo injetar dados *humanos*, como relatórios de incidentes, chamados históricos, documentação de arquitetura e código-fonte e cruzar essas informações com *logs* de erros para compreender a fundo o contexto do sistema.

Metodologia (Solução Proposta)

Na taxonomia das tarefas operacionais, a resolução de incidentes foi dividida em três etapas lógicas: Detecção de anomalias, Análise de Causa Raiz (RCA) e Remediação. A RCA evoluiu da simples categorização de erros para a geração de relatórios explicativos completos em linguagem natural. Do ponto de vista prático de implementação, o estudo demonstra que treinar modelos gigantes do zero ou realizar *fine-tuning* completo é inviável e caro. O que predomina de fato é a utilização de *Retrieval-Augmented Generation* (RAG) para buscar incidentes semelhantes na base de conhecimento e *In-Context Learning* (ICL), que injeta os dados da falha diretamente via engenharia de *prompt*. Destaca-se também a Geração Aumentada por Ferramentas (*Tool Augmented Generation*), onde o modelo consome APIs de monitoramento de forma autônoma para investigar o problema antes da resposta final.

Resultados Obtidos (e Avaliação)

A pesquisa evidencia que a remediação 100% automática (onde a IA age sozinha executando comandos) ainda é extremamente limitada e precisa de rigorosa validação prática. O principal gargalo do mercado recai sobre a avaliação da IA: métricas tradicionais falham em mensurar texto gerado, forçando as equipes a adotarem avaliação humana manual ou métricas semânticas complexas na tentativa de barrar as alucinações das respostas.

Relação com este TCC

O principal ganho deste artigo para a pesquisa é a constatação técnica de que os LLMs apresentam alto custo financeiro, energético e de latência. O estudo argumenta que é computacionalmente inviável utilizar um LLM para ler métricas continuamente em tempo real. Esta conclusão **está fortemente alinhada com a arquitetura proposta neste TCC**: a abordagem adotada busca não substituir a *stack* de monitoramento existente, mas sim focar na integração. Seguindo as direções da pesquisa, o projeto utilizará ferramentas consolidadas para a detecção de anomalias (Prometheus/Alertmanager), acionando o LLM como um *middleware* restrito à etapa de RCA, otimizando o esforço cognitivo apenas quando o alerta é disparado.